

## Seção 2

**Deteccção de emoções e expressões faciais:** Analisar imagens e/ou vídeos e indicar qual a emoção predominante a partir de características faciais. As expressões faciais fornecem informações essenciais e desempenham um papel crucial na interação entre as pessoas, servindo como uma forma importante de comunicação não verbal, fornecendo uma mensagem. Dito isso, a técnica mais usada para trabalhar com expressões faciais é o Deep Learning e Redes Neurais Convolucionais.

**Aplicações:** Como citado, nos carros inteligentes alertando os condutores distraídos, encontrar a melhor forma e o melhor momento para entregar a direção para o motorista, entre outras aplicações, como jogos, saúdes, educação e marketing.

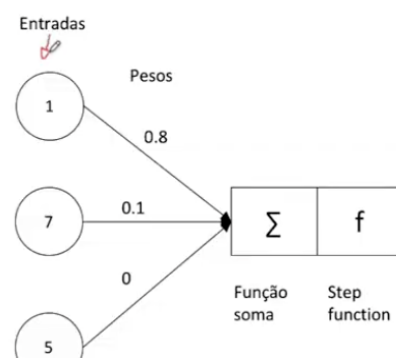
Etapas: Operador de convolução aplica o detector de características(filtro/feature detector) e multiplicará pela imagem de entrada, e no final teremos o mapa de características(feature mapa), focando apenas nas partes principais da imagem. Depois temos a segunda etapa, o Pooling, aplicando uma fórmula, o max pooling voltará o valor máximo da aplicação, focando em características mais importantes. Na etapa três temos o Flattening, que transformara o mapa em um vetor, e por último, submeter este vetor encontrada em camadas da rede neural

## Secao 3:

A secão 3 foi pratica, aprendemos como mexer com imagens para reconhecer emocoões, funcoes que fazem, ajustes de imagem para facilitar a rede neural e tambem as funcoes de ativacoes. Tambem, aprendemos a mexer com video, sobre como reconhecer em videos.

## Secao 4:

**Neuronio artificial:** Um neurônio artificial é o componente fundamental de uma rede neural, simulando o comportamento de um neurônio biológico, processando informações para gerar uma saída, onde cada neurônio recebe



múltiplas entradas (inputs), que são valores numéricos, como características de dados ou pixels de uma imagem. Essas entradas são multiplicadas por pesos que determinam a importância de cada entrada e além disso, um termo de bias é adicionado à soma ponderada das entradas para melhorar a flexibilidade do modelo.

**Gradiente:** O gradiente é um vetor que aponta na direção de maior taxa de variação de uma função, ele indica a direção em que uma função cresce ou diminui mais rapidamente a partir de um ponto específico, com um custo mínimo (loss function).

**Delta:** O cálculo do delta em redes neurais é usado para ajustar os pesos durante o backpropagation, para a camada de saída, o delta é a diferença entre a saída real e a prevista, multiplicada pela derivada da função de ativação, já nas camadas ocultas, o delta é o erro propagado da camada seguinte, ajustado pelos pesos e pela derivada da função de ativação, esse processo permite que a rede aprenda e minimize

**Back Propagation:** Algoritmo utilizado para ajustar os pesos de uma rede neural durante o treinamento, ele calcula o erro da saída da rede e propagando esse erro de volta através das camadas e em cada iteração, os pesos são ajustados com base no erro calculado, utilizando as derivadas da função de ativação, até que a rede minimize o erro e melhore a precisão das previsões.

**Bias:** é um valor adicional que ajuda a ajustar a função de ativação de um neurônio, permitindo que a rede neural aprenda padrões complexos, agora o erro é a diferença entre a previsão da rede e o valor real, usado para ajustar os pesos durante o treinamento.

**Descida do gradiente estocástica (SGD):** é um algoritmo de otimização que ajusta os pesos iterativamente, calculando o gradiente do erro e atualizando os pesos na direção oposta, os parâmetros como a taxa de aprendizado, número de épocas e tamanho do lote influenciam a eficiência e performance do treinamento da rede neural.

### **Funcoes de Ativacao:**

**-Step Function (Função Passo):** é uma função de ativação simples que retorna um valor fixo (normalmente 0 ou 1) dependendo se a entrada é maior ou menor que um limiar definido, sendo usada para decidir se um neurônio é ativado ou não, mas tem limitações, como não ser diferenciável, o que dificulta seu uso em redes neurais modernas.

**-Sigmoid:** é uma função de ativação que mapeia qualquer valor de entrada para um intervalo entre 0 e 1, de forma suave e contínua, onde  $e$  é a base do logaritmo natural. A sigmoide é usada em redes neurais para modelar probabilidades, mas tem como limitação o desvanecimento do gradiente, que pode dificultar o treinamento de redes profundas.

**-Tangente Hiperbólica (tanh):** é uma função de ativação similar à sigmoide, mas com um intervalo de saída entre -1 e 1, em vez de 0 e 1, mais eficaz que a sigmoide em muitos casos, pois tem uma média de 0 para valores de entrada próximos de 0, o que pode ajudar na convergência do modelo. No entanto, assim como a sigmoide, ela também pode sofrer com o problema de desvanecimento do gradiente quando usada em redes neurais profunda

**-ReLU (Rectified Linear Unit)** é uma função de ativação que retorna 0 para entradas negativas e o próprio valor para entradas positivas, sendo rápida de calcular e ajuda a evitar o problema de desvanecimento do gradiente, mas pode levar à "morte" de neurônios, onde certos neurônios não atualizam mais seus pesos.

**-Função Softmax** é uma função de ativação usada principalmente em problemas de classificação multiclasse, convertendo um vetor de valores em uma distribuição de probabilidade, ou seja, a soma das saídas será sempre 1, onde cada valor de saída representa a probabilidade de uma classe, sendo que a classe com a maior probabilidade será a escolhida como a previsão do modelo, sendo muito utilizada na camada de saída de redes neurais para tarefas de classificação.